

第二轮独立复核 · 2026-09-14

Spectral Sphere 复核意见

复核对象：你对 *Controlled LLM Training on Spectral Sphere* (arXiv:2601.08393v3) 的审查结论、`SSO_Audit_Report.pdf` 与 `SSO_Audit_Evidence.zip`。本次全部结论由独立重算得到：论文 22 页逐节复读、反例用 NumPy 重建、官方仓库重新克隆 (`Unakar/Spectral-Sphere-Optimizer`)、公开 CSV 重算、并用作者自己的 `sso.py` 实测数值精度。

你的方向是对的，但三项发现的权重排错了：数学反例被高估，评测漏洞被误置为核心，而你手上最强的证据——实验优势在计入时间后消失——被排到了第四条。

论文确实不能按“理论无漏洞、实验完整可复现”通过。但支撑这个结论的最有力事实不是 Theorem A.3，而是：**在等墙钟预算下，SSO 相对 MuonSphere 的优势反转为 -0.003，相对 Muon 只剩 0.004；Table 3 中 SSO 对 MuonSphere 的差异 $z = 0.31$ ，其中 77% 来自一门所有模型都只有随机水平的任务。**把审查意见重写成这个顺序，作者很难反驳；按现在的顺序，作者只需回一句“反例在我们的矩阵形状下不会发生”就能卸掉第一条。

一、对你三条主要结论的复核

确证 严重性下调 p20 Theorem A.3 · 式 (11)-(12) · Algorithm 1 第 9-11 行

数学反例成立，而且比你写的更干净；但它的实际射程很小

我独立重建了 $W=\text{diag}(1, \frac{1}{2})$ 、 $\Theta=e_1e_1^T$ 、 $G=[[0,1],[1,2]]$ ，逐点复算 $h(\lambda)$ ：左支上确界 -0.6，奇点取 1/5，右支恒为 1，**确实不存在零点**；最优切向解 $T_*=vv^T-\frac{1}{4}nn^T$ 的谱范数为 1、 $\langle \Theta, T_* \rangle = 0$ 、目标值 2.5，恰等于 $\|G + \frac{1}{2}\Theta\|_*$ ，所以它确实是精确最优，作者遗漏的正是零奇异子空间的补全。论文那句“subgradient + 单调不减 $\Rightarrow$ 介值性”是明确的逻辑错误：Darboux 性质属于处处存在的导数，不属于非光滑凸函数的任意次梯度选择。这一条我完全支持，并且可以补一个更清晰的修法： `$f(\lambda) = \|G + \lambda\Theta\|_*$` 是凸且强制的 ($f(\lambda) \geq |\lambda| - \|G\|_*$)，**极小点 λ_* 永远存在**，二分法找到的也正是它——真正错的只是“把 $\text{msign}(G + \lambda_*\Theta)$ 当成最优方向”这一步。

但你写“影响式 (11)–(12) 作为通用精确切向 oracle”之后就停住了，没有回答作者一定会问的那句：这在我们的实验里会发生吗？我做了这个测量。h 的跳跃只出现在 $G+\lambda\Theta$ 降秩处，而 $m\times n$ 仿射族降秩的余维是 $|m-n|+1$ ——非方阵在单参数族里一般根本不降秩。方阵情形我用随机矩阵测了失败率：

方阵 $n\times n$ ，高斯 G ，随机秩一 Θ ；失败 = h 在奇点两侧跨零							
N	2	4	8	16	32	64	128
无零点概率	0.51	0.26	0.14	0.11	0.03	0.025	0.00
跳跃中位幅度	0.85	0.31	0.14	0.074	0.035	0.017	—
目标值相对损失	1.8e-2	1.1e-2	<1e-4	6.7e-5	1.4e-5	8.7e-6	—

失败概率约按 $1/d$ 衰减， $d\geq 128$ 已测不到；把 G 换成幂律谱（更接近真实动量）后同样测不到。而 Dense-1.7B 里 SSO 管辖的 2D 权重是 128×2048 、 6144×2048 、 2048×6144 、 2048×128 ——除了未拆头的 **o_proj (2048×2048)** 之外全是非方阵。也就是说：定理陈述是错的，必须改；但它不足以解释实验里的任何现象，而且作者可以正当地这样回应。你在报告里已经写了“不证明真实训练必然频繁遇到”，我建议把它升格成一张上面这样的表，主动把射程钉死——否则这条会被当成纸面瑕疵略过。

还有一个更有说服力的量级对照，见下面第三部分第 3 条：作者自己实现的 **msign** 误差比这个理论缺口大三个数量级。

确证为代码缺陷 对论文的证明力最弱 megatron/training/benchmark.py · prepare_benchmark.sh

评测计分漏洞是真的，但你自己的证据链已经指向“Table 3 不是这条路跑出来的”

把无条件校准请求（`doc_id+1000000`、context 为 `Answer:`）当成独立考题计分，这是确定的缺陷，CSQA 1221→2442 的复现也干净。但你在报告正文把它列为“最严重的代码问题”，而在证据包 `experiments/findings.md` 里其实已经给出了反向指标。我重算了那个整除性推断：

论文四列百分数能由哪个样本量的整数正确数产生（单次、等权、四舍五入两位）			
任务	公开包 N	漏洞加倍后 N	标准全集 N
ARC-Easy	570 — 不相容	1140 — 不相容	2376 — 相容
ARC-Challenge	299 — 不相容	598 — 不相容	1172 — 相容
HellaSwag	1000 — 不相容	2000 — 不相容	10042 — 相容
CSQA	1221 与 2442 均相容（无法区分）		—

三个任务同时只与标准全集相容、且同时排除公开包的两种规模，这不是巧合。合理推断是：**论文用的是另一套评测链，跑在完整 test/val 全集上，因而这个 bug 大概率没有污染 Table 3。**那么这条发现的正确定位不是“论文数字可疑”，而是“**公开脚本无法产生论文表格**”——这恰恰是更硬的复现性指控，而且不需要指控任何人算错。建议把它从“最严重的代码问题”改写为“复现链断裂的直接证据”，并把 CSQA 单独拎出来问：它是唯一无法区分的一列，唯一不在四份公开 eval 脚本任务表里的一列，也是四个优化器都停在五选一随机水平（19.0–21.1）的一列。三件事同时成立，需要作者给出逐题输出。

确证 应升为首要结论 Table 2 · Figure 8 · Table 3

“省步数不等于省时间”——你算对了，但只用了它的一半力量

我用官方 `standard_baseline.csv` 重算，完全复现你的数字：以 AdamW 第 23000 步 loss 2.5882823 为阈值，Muon 省 11.90%、MuonSphere 省 14.05%、SSO 省 19.39%（1.2406×）；按 Table 2 单步延迟折算，SSO 比 Muon 慢 1.97%。但真正该摆在最前面的是下面两条你没做的推算。

到达 AdamW@23k 验证损失所需的 GPU 小时

公开 loss 曲线 × Table 2 单步延迟（B200，4M tokens/step）。绿色为最优。

AdamW		43.02 h
Muon		38.72 h
MuonSphere		38.16 h
Spectral Sphere		39.48 h

SSO 是三种谱方法里最慢的一个：比 Muon 慢 1.97%，比 MuonSphere 慢 3.45%——尽管它比 MuonSphere 少用 6.2% 的步数。

（1）等墙钟下优势反转。把两条曲线都按 Table 2 折成时间轴，在共同预算 44.6 GPU 小时处比较验证损失：SSO 2.556193，MuonSphere 2.553201，Muon 2.560627。**SSO 对 MuonSphere 由 -0.0108 变成 +0.0030（变差），对 Muon 由 -0.0187 缩到 -0.0044。**论文全篇没有一处按时间比较，而它自己的 Table 2 就足以做出这个反转。这是整份审查里最难反驳的一个数字。

（2）Table 3 的差异在统计上等于零。用上面推断出的样本量做二项标准误（单次评测、未配对，已是对论文最有利的假设）：

SSO - MuonSphere, 逐任务					
任务	N	差值（PP）	SE	Z	对均值贡献
LAMBADA	5153	-0.48	0.94	-0.51	-0.060
...	...	...	...	...	...

CSQA	1221	Spectral Sphere 复核意见			
		+0.78	1.04	0.00	+0.123
PIQA	1838	+0.98	1.42	0.69	+0.123
HellaSwag	10042	+0.05	0.71	0.07	+0.006
WinoGrande	1267	+0.94	1.91	0.49	+0.118
ARC-e	2376	+0.29	1.31	0.22	+0.036
ARC-c	1172	-0.09	2.01	-0.04	-0.011
BoolQ	3270	-1.40	1.17	-1.20	-0.175

八项平均 +0.15875 pp，该平均值的标准误 0.513 pp，**z = 0.31**；单项无一超过 |z|=1.2。更要命的是：**+0.159 pp 里有 77% 来自 CSQA 这一门所有优化器都只有随机水平（20%）的任务**。这已经不是“没有多种子所以不能判断稳定性”，而是“即使只看单次评测的抽样噪声，这个差异也读不出来”。这个论证不需要作者提供任何补充材料就能成立，应当写进你的执行摘要。

二、我新增的发现

以下各条在你的报告与证据包中未出现，或只以静态代码阅读的形式出现而没有量化。

新增 sso.py `_msign`、`_power_iteration` vs 正文 §5.2

1. 论文写的精度策略与代码完全相反

§ 5.2 写：“Power Iteration 用 BFloat16，敏感的 msign 保持 FP32、8 次迭代”。我读官方 `sso.py`：`_msign` 第一行 `X = G.bfloat16()`；`_power_iteration` 第一行 `W = W.to(torch.float32)`。**两者恰好互换**。这不是你证据包里 Megatron 分支的注释矛盾，而是独立仓库主文件里的直接对立，作者无法用“分支漂移”解释。

新增 8-step Polar Express, 实测

2. 实现的方向误差比那个理论缺口大三个数量级

我直接调用作者的 `_msign` 与精确 SVD 对比：

msign 相对误差 $\ X - UV^T\ _F / \ UV^T\ _F$ ，高斯矩阵					
形状	256 ²	512 ²	1024 ²	2048×512	128×2048
出厂 BF16	0.0119	0.0342	0.0323	0.0071	0.0058
论文声称的 FP32	0.0106	0.0320	0.0307	0.0000	0.0000

两个结论：方阵/病态矩阵上 8 步 Polar Express 本身就有 1–3.4% 的截断误差，**不是 BF16 造成的**；而在条件数好的矩形矩阵上 FP32 能收敛到机器精度，BF16 却把误差抬到 0.6%——所以那个精度互换是有实际代价的。对照第一部分：Theorem A.3 失效时的目标值损失是 $1e-5$ 量级。**作者投入整个 λ 求解器去修的那个方向偏差，比他们自己的 `msign` 近似误差小三个数量级**。这是评价这篇论文“理论贡献的实际价值”最关键的一句话，也是我建议你写进摘要的第二句。

新增 `sso.py` `_power_iteration`；正文脚注 2

3. 谱间隙不只影响泰勒余项，它直接决定 Θ 本身算得准不准

你的报告第 4 条指出余项常数依赖谱间隙，这是对的，但还可以再进一步：**方法的数学核心 $\Theta = u_1 v_1^T$ 是用幂迭代估计的，而幂迭代的收敛速度正比于 σ_1/σ_2 的间隙——也就是论文用“重根是测度零事件”一句带过的那个量**。实测（高斯 W ）：

出厂幂迭代（全 1 初值，不缓存）对比精确 SVD			
形状	步数	Σ 相对误差	$ \langle u, u_1 \rangle $
512×512	5（ <code>sso.py</code> 默认）	6.1e-2	0.213
512×512	20	8.6e-3	0.445
512×512	100（Megatron 脚本）	2.0e-3	0.845
2048×512	5	6.7e-2	0.061
2048×512	100	4.8e-3	0.647

公平地说：论文的大模型脚本用的是 100 步，不是独立仓库的默认 5 步，所以 σ 的估计误差约 0.5%（这已经说明“严格满足 $\|W\|_2=R$ ”只在 0.5% 意义上成立）。但即使 100 步，**返回的 u 与真正的 u_1 的重合度只有 0.65–0.85**——一切空间投影器本身就是歪的。我把它列为“待实测”而不是“确证缺陷”：高斯矩阵的 σ_1/σ_2 间隙是最坏情况，真实训练权重可能更好。但这恰恰说明**作者必须在真实 run 里记录 σ_1/σ_2 与 $|\langle u_{PI}, u_1 \rangle|$** ，而仓库里没有任何诊断做这件事。

新增 `sso.py` `_solve_lambda`

4. 求解器的搜索区间比论文自己的定位定理小两个量级，且失败时静默

你的证据包 R6 记录了“`bracket` 失败返回 $\lambda=0$ 并被调用方忽略”。补充两点：出厂实现从 `init_step=1e-3` 起倍增、`max_expand=10`，**搜索半径上限 ≈ 1.023** ；而 Theorem A.3 保证的区间是 $|\lambda_*| \leq 2 \|G\|_*$ ，对 Frobenius 归一化后的动量， $\|G\|_*$ 可达 $\sqrt{\min(d_{out}, d_{in})}$ 量级（2048 维下约 30–45），即区间应为 ± 60 –90。二者差两个数量级。其次，独立仓库里失败时返回的是 `init`，也就是**上一步的 λ** （不是 0），这比“退化为 μ_{on} ”更难分析。再次，

我实测出厂求解器在 $\text{tol}=2\text{e-}4$ 下返回的 λ_* ，用精确 SVD 复核的真实切向残差是 $1\text{e-}4 \sim 1.8\text{e-}3$ ，而精确求解可达 $1\text{e-}17$ ——“严格切向约束”实际只成立到 10^{-3} ，且判据本身用的是带噪声的 h ，所以求解器会在真实残差大 5 倍时报告成功。

新增 figures_in_paper/raw_data/mup/*.csv, §6.1

5. 学习率公平性：对论文有利，但暴露出 SSO 的适用区间很窄

主实验四种优化器统一用 $5\text{e-}3$ (AdamW 的最优点)。我用公开 μP 扫描 CSV 算了各学习率下 Muon 与 SSO 的损失差 (width=2048, 30B tokens)：

Muon loss - SSO loss, 正数表示 SSO 更好								
LR	1E-3	3E-3	5E-3	7E-3	9E-3	1E-2	1.5E-2	2E-2
差值	-0.036	-0.014	+0.002	+0.010	+0.013	+0.013	+0.007	-0.011

两件事同时成立，你的报告两件都没说：（a）主实验的 $5\text{e-}3$ 恰好是 SSO 优势最小的点 (+0.002)，在调好的 $1\text{e-}2$ 上优势是它的 5.5 倍——所以“统一 LR 不公平”这条批评方向上是有利于论文的，你如果按现在的写法提出来，作者会用它反击；（b）SSO 只在 $7\text{e-}3$ – $1.5\text{e-}2$ 这个窄带里赢，在 $\leq 3\text{e-}3$ 输给 Muon，在 $\geq 2\text{e-}2$ 崩得比 Muon 更快 ($3\text{e-}2$ 时差 0.05)。这与“稳定、鲁棒、 μP 对齐”的叙事相冲突，是更值得提的一条。

新增 Figure 2、Figure 12、附录 A.5

6. μP 学习率迁移的主张 (Figure 2 摘要级论断) 基本没有证据支撑

正文说 “Muon still exhibits notable optimal learning rate drift, in contrast Spectral Sphere achieves stable LR transfer”。按公开 CSV 重算四个宽度的最优点：SSO 全部 0.010；Muon 是 0.009 / 0.015 / 0.010 / 0.010；AdamW 是 0.003 / 0.003 / 0.003 / 0.005，同样只漂了一格。Muon 唯一那次“漂移”出现在 width=512，而 0.015 与 0.010 的 loss 只差 0.0024。九点粗网格、单种子、差值在噪声量级——这组数据支持不了任何关于 LR 迁移性的定性差异，Figure 12 的 caption 说 AdamW “drifting optimal LR” 同样如此。这是摘要里被反复引用、而证据最薄的一条主张，你完全没有提到。

新增 式 (14), §3.3

7. 取消 weight decay 的理由是一个松了 $\sqrt{d}$ 的界

论文用 $\|W\|_F \leq \sqrt{\text{rank}(W)} \cdot \|W\|_2 \leq \sqrt{\min(d_{\text{out}}, d_{\text{in}})} \cdot R$ 论证“权重幅度自动被限制，weight decay 因此冗余”。这个界本身正确，但 $d=2048$ 时 $\sqrt{d} \approx 45$ ：约束 σ_{max} 完

全不约束谱的主体，权重仍可在除顶奇异方向外的所有方向上自由增长 45 倍。论文在 § 7 把“内部谱自由演化”当成相对 Stiefel 流形的优点，那就不能同时用式 (14) 论证 weight decay 冗余——两处论证互斥。取消 weight decay 的真实依据只能是 § 6.1 那句“1.7B 消融上关掉稍好”的经验观察，应该如实这样写。

新增 外部文献

8. 后续独立工作已经给出旁证

- [Demystifying Manifold Constraints in LLM Pre-training](#) (MACRO) 系统比较谱约束与 Frobenius 约束，结论是在有 RMSNorm 的常规结构下两者表现几乎相同，只有在去掉可学习归一化时谱约束才明显更好；并明确因算力限制未能在 1B 规模上与 SSO 对比。这对 SSO “谱球面是唯一正确几何”的叙事是直接的稀释。
- [Manifold constrained steepest descent](#) 引用了 SSO，但刻意避开嵌套的对偶求解，改用单回路 LMO+投影，理由正是内层求解的成本——与我们算出的 +11.45% 单步开销一致。
- [Hyperball Optimization](#) 观察到矩阵类优化器相对 AdamW 的加速随模型与数据规模从约 30% 缩到约 10%。SSO 在 1.7B/100B 上报告的 19%（按步数）落在这条趋势里，不构成异常增益。

把这三条放进审查意见，可以把“单篇复现失败”提升为“与领域内独立结果一致的判断”。

三、我认为应当降级或撤回的表述

降级

式 (29) 的矩阵极限、式 (32) 的不等式顺序

两条我都核对了。式 (32) 原文确实写成 $\|G\|_* - \lambda \| \theta \|_* - \|G\|_*$ ，没有绝对值号，按字面推不出 $\lambda - 2 \|G\|_*$ ——你的指控成立（我一度以为是你漏看了绝对值，查了 PDF 文本层才确认没有）。式 (29) 的矩阵极限也确实不成立。但这两条都是补一对绝对值号、改一句措辞就能修好的排版级错误，标量极限与定位结论都不受影响。把它们与 Theorem A.3 并列写在“数学推导存在实质错误”下面，会稀释真正的那一条。建议单独归入“editorial corrections”。

降级

pre-/post-retraction “不严格等价”

结论正确，但你的数值例子用 $\eta=0.1$ 、 $R=1$ ，是论文实际学习率（ $5e-3$ ，且 $R=\sqrt{(d_{\text{out}}/d_{\text{in}})}$ 常小于 1）的 20 倍以上。在真实超参下这个差异是 $O(\eta^2) \approx 10^{-5}$ 量级，而附录 A.3 本来就写了 $O(\eta^2)$ 。正文那句“operationally equivalent”确实过强，但这是措辞问题，不是算法缺陷。按现在的写法容易被当成夸大。

降级

“谱范数上界不能推出 $\Theta(1)$ 激活”

数学上无可指摘，但这条批评同样适用于 Yang-Simon-Bernstein 的整个 spectral condition 传统，不是这篇论文特有的漏洞。更有杀伤力的版本是具体的：**Figure 1 比较的是开了 weight decay 的 Muon 与关掉 weight decay 的 SSO**，激活漂移的归因因此被混淆；而作者自己在 § 5.3 承认 residual stream 仍是 outlier 主源。用这两条实证矛盾，比用反例讲“上界不是下界”更难被绕过。

澄清

19.39% 的阈值依赖性

你指出换成最后一个点（23841 步）会变成 $1.309\times$ 。我复算了整条敏感性曲线：阈值取 20000/21000/22000/23000/23841 时，SSO 的省步数分别是 19.35 / 18.63 / 18.36 / 19.39 / 23.62%。**方向是：论文选的那个阈值反而偏保守。**所以这条不能写成疑似择优报告，写成“该数字定义敏感、必须随定义引用”即可，否则会被正当地驳回。

四、目前无法判定的事项

以下问题即使把你的证据包和我这轮复核合起来也回答不了，必须由作者交材料或由新实验解决。按“阻塞程度”排序。

- **Table 3 究竟由哪条评测链产生。**整除性推断是条件推断，若作者做过多次平均或加权即失效。需要：生成表格的 commit、每任务 split/shot 配置、逐题 logprob 与预测文件。
- **SSO 相对 MuonSphere 那 0.011 的最终 loss 差是否跨种子稳定。**公开 CSV 无 seed 字段，图中色带是单条曲线相邻两点的 1%/99% 滚动分位数，不是置信区间——这一点你的证据包查出来了，但没写进结论摘要，而它会让读者误读所有曲线图，应当写进去。
- **Table 1/2 的计时是否在同一并行度、同一重计算设置下测得。**AdamW 脚本开了全量 activation recomputation 而 SSO 脚本没开；若 AdamW 的 6734 ms 含重计算开销，等墙钟结论只会对 SSO 更不利，但方向需要作者确认。也没有找到端到端 profiler 原始日志。
- **宣传的系统优化在计时 run 里是否启用。**README 列了 Adaptive Kernel Dispatcher 与 Cached Singular Vectors，而默认路径里 msign 分派是 `if True` 恒走小矩阵分支、幂迭代每步从全 1 重启。需要作者指明 Table 1/2 对应的 commit。
- **真实 run 中求根失败率、切向残差、 $\|W\|_2/R$ 偏差、 σ_1/σ_2 分布。**目前仓库没有任何一处记录，而“严格约束”是论文的核心卖点。
- **19%/12% 的省步数在调好的 $1e-2$ 上是多少。** μP 扫描显示 SSO 的优势在 $1e-2$ 上大 5.5 倍，主曲线若在最优 LR 下重跑，步数优势可能更大——但单步开销不变，等墙钟结论未必改变。这是唯一可能推翻我上面第一条新增结论的实验。

- **DeepNet-200 层与 MoE 的下游结果。**200 层只报训练 loss，原始数据不在仓库；MoE 与 200 层实验都缺 MuonSphere 对照（Figure 9b、Figure 10），而 MuonSphere 恰是唯一能隔离入求解器贡献的对照组。
- **Figure 9(b) 的列名问题。**`triple.csv` 里 `muonball_value` 被绘图脚本改名为“spectral sphere”，代码里还有一句注释说明。需要 run ID 才能确认对应关系，不能自行判定。

五、建议的实验顺序

你现在的方案是“先修评测接口 → 四组小模型对照”。方向对，但第一步应该是一件不需要训练、当天就能出结论的事，而且它的判别力比换数据集大得多。

1

插桩跑 200 步，不需要新模型

拿官
方
`ss0.py`
直接
改出
一个
记录
版，
在
130M
模型
上跑
200
步，
每步
记
录：
更新
后
 $\|W\|_2/R$
的实
际偏
差、
用精
确
SVD

复核
的切
向残
差
 $\langle \Theta, \Phi \rangle$ 、
 $\sigma_1 /$
 σ_2 、 $|$
 $\langle u_{PI}, u_1 \rangle$ 、
bracket
失败
次
数、
msign
的正
交性
残
差。
这一
步单
独就
能判
定
“严
格谱
约
束”
“精
确切
向方
向”
“ $\Theta(1)$
激
活”
三条
卖点
是否
在实
现层
面成
立，
成本

接近
零。
先做
这
个，
再决
定要
不要
花
GPU。

2

等墙钟对照，而不是等步数对照

AdamW
/
Muon
/
MuonSphere
/
SSO，
130M-
350M
模
型，
2-5B
tokens，
每个
优化
器各
自扫
至少
3个
学习
率，
3个
种
子。
同时
报告
loss-
vs-
steps

与
loss-
vs-
wall-
clock
两条
曲
线，
以及
到达
同一
loss
的实
测
GPU
小
时。
这是
唯一
能证
实或
推翻
“等
墙钟
下优
势反
转”
的实
验，
也是
整份
审查
的胜
负
手。
注意
MuonSphere
必须
在列
——
它是
、

$\Lambda=U$
的消
融，
SSO
的全
部理
论贡
献就
体现
在这
一个
对照
上。

3

把 λ 求解器单独隔离出来

同一
批种
子下
跑三
个变
体：
MuonSphere
($\lambda=0$)、
SSO
(出
厂
NS
近
似)、
SSO-
exact
(精
确
SVD
求
msign
与完
整次
梯度
补
全)。

如果
SSO-
exact
与
SSO
无差
别，
说明
论文
的数
学贡
献被
自己
的数
值近
似淹
没；
如果
SSO
与
MuonSphere
无差
别，
说明
贡献
来自
谱归
一化
而非
切向
求
解。
**这两
种结
果都
能独
立成
文，
而且
都不
需要
100R**

~~~~

tokens。

4

修评测链，同 checkpoint 交叉验证

剔除  
无条  
件请  
求或  
正确  
配对  
做  
PMI；  
用同  
—  
checkpoint  
同时  
跑仓  
库评  
测器  
与  
OLMES/lm-  
eval-  
harness，  
逐题  
logprob  
对  
齐；  
raw  
/ 字  
符归  
一化  
/  
token  
归一  
化 /  
PMI  
分开  
标  
注；  
配对  
bootstrap

罢信

具口

区

间。

注意

仓库

的

acc\_norm

按

token

数归

一，

而下

载包

config

写的

是

acc\_per\_char

——

这不

是数

学错

误，

但同

名不

同

义，

必须

改名

或改

实

现。

5 最后才换语料

只有

前四

步通

过，

换语

料才

有意

义。

从主

孙衣

里的

FineWeb-

Edu

是对

的选

择；

WikiText-

103

我建

议降

级

——

在

100M+

参数

下它

测的

是过

拟合

而不

是优

化；

TinyStories

只作

为数

值稳

定性

的机

制检

查，

不要

用它

的指

标参

与胜

负判

断。

补一

条：

跨

tokenizer

比较  
时报  
bits-  
per-  
byte  
而非  
PPL,  
否则  
数字  
不可  
比。

## 六、数据集认可度：结论不变，但要补两句

你的判断正确——OLMo-Mix-1124、ARC、PIQA、HellaSwag、BoolQ、WinoGrande、LAMBADA 的认可度都没有问题，问题在协议而不在数据。两点补充：

- **CSQA 那一列需要单独处理。**四个优化器全部落在 19.0–21.1，而五选一随机是 20.0。OLMES 已经记录小型 base model 在字母选择格式下接近随机、在 completion 格式下明显更高，所以这不必然是 bug；但它同时是唯一不在公开 eval 脚本任务表里的任务、唯一样本量无法区分的任务、以及贡献了 SSO 全部平均优势 77% 的任务。**在拿到逐题输出之前，这一列不应参与任何结论。**
- **“换数据集”不能替代“修评测”。**你的表已经写了这句，值得再强调一次：当前最大的不确定性来自协议与统计功效，不来自语料覆盖面。在同一份 checkpoint 上把评测协议钉死，比新增三个语料更能改变结论。

## 七、总结：建议如何重写你的执行摘要